AGEO RECHERCHE

Graphe de connaissances scientifiques et comparaison Cypher / GraphRAG

Rapport V3 - corpus élargi et exécutions réelles

Cette version élargit le corpus à 25 résumés arXiv, corrige les auteurs depuis les métadonnées HTML et ajoute les sujets extraits avec Gemini 3.1 Flash-Lite. Les données passent réellement par HDFS et Spark avant leur import dans un graphe Neo4j distinct du graphe historique.

Élément vérifié	Résultat observé
Corpus	25 articles HTML ; affiliations issues de 3 en-têtes PDF
HDFS	25 HTML originaux et 28 extractions relus et vérifiés
Spark	28 documents ; 382 relations ; mode local[2]
Neo4j V3	289 entités + 28 documents sources ; 382 relations ; PageRank GDS exécuté
Modèle de sujets et réponses	gemini-3.1-flash-lite, proposé sur le palier gratuit
Benchmark	60/60 paires terminées ; état complete
Vérification locale	44 tests réussis ; API et interface contrôlées

Les références restent provisoires. Elles ont été préparées par l'assistant à partir des textes et métadonnées, sans relecture humaine indépendante attestée. Les résultats de qualité ci-dessous ne constituent donc pas une validation scientifique finale.

Aucune activation de facturation n'a été effectuée. Les jetons et mots de passe restent dans le fichier .env local, exclu des livrables. Le rapport V2 est conservé comme historique ; ses mesures ne sont pas mélangées à celles de V3.

1. Corpus et périmètre documentaire

La collecte conserve les pages HTML originales, leurs empreintes et les métadonnées citation_title, citation_author et citation_abstract. Les titres ci-dessous sont abrégés si nécessaire ; le corpus complet figure dans data/corpus-v3/articles.json.

arXiv	Publication	Auteurs	Sujets
1706.03762	Attention Is All You Need	8	1
2005.11401	Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks	12	3
2404.16130	From Local to Global: A Graph RAG Approach to Query-Focused Summarization	10	4
1810.04805	BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding	4	2
1802.05365	Deep contextualized word representations	7	2
1907.11692	RoBERTa: A Robustly Optimized BERT Pretraining Approach	10	2
1910.10683	Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer	9	3
2004.04906	Dense Passage Retrieval for Open-Domain Question Answering	8	1
2007.14062	Big Bird: Transformers for Longer Sequences	11	4
2004.05150	Longformer: The Long-Document Transformer	3	5
2002.08909	REALM: Retrieval-Augmented Language Model Pre-Training	5	4
1906.00300	Latent Retrieval for Weakly Supervised Open Domain Question Answering	3	1
1911.00172	Generalization through Memorization: Nearest Neighbor Language Models	5	1
2001.08361	Scaling Laws for Neural Language Models	10	2
2005.14165	Language Models are Few-Shot Learners	31	3
2302.13971	LLaMA: Open and Efficient Foundation Language Models	14	1
2307.09288	Llama 2: Open Foundation and Fine-Tuned Chat Models	68	3
2310.06825	Mistral 7B	18	3
2203.02155	Training language models to follow instructions with human feedback	20	1
2201.11903	Chain-of-Thought Prompting Elicits Reasoning in Large Language Models	9	2
2205.11916	Large Language Models are Zero-Shot Reasoners	5	2
2210.03629	ReAct: Synergizing Reasoning and Acting in Language Models	7	3
2305.10601	Tree of Thoughts: Deliberate Problem Solving with Large Language Models	7	1
2212.10496	Precise Zero-Shot Dense Retrieval without Relevance Labels	4	3
2104.07567	Retrieval Augmentation Reduces Hallucination in Conversation	5	3

Chaque identifiant renvoie à https://arxiv.org/abs/<identifiant>. Les trois PDF initiaux correspondent à 1706.03762, 2005.11401 et 2404.16130. Seuls leurs en-têtes et affiliations sont exploités, pas leur texte intégral.

2. Construction, preuves et stockage

Des sources hétérogènes, des méthodes séparées

Les 293 relations AUTHORED proviennent des métadonnées HTML. Les 60 relations ABOUT proviennent de cinq appels Gemini sur les 25 résumés. Les 29 assertions AFFILIATED_WITH sont reprises des extractions PDF antérieures avec leurs sources : cette reprise ne corrige pas automatiquement les affiliations manquantes.

Les identifiants de publications reposent sur arXiv. Les noms d'auteurs sont normalisés, notamment Łukasz/Lukasz. Le rapprochement par nom ne résout pas les homonymes ; cette limite s'applique aux agrégations entre articles.

Validation des citations

Les espaces, ligatures et césures sont normalisés pour rechercher les citations. Une citation absente est supprimée sans invalider les autres faits : deux citations de sujets ont été rejetées. Les assertions conservent le texte original et le type de source. Les sujets sont vérifiés contre le résumé décodé, les auteurs contre le HTML brut et les affiliations contre le texte PDF.

La présence d'un extrait ne démontre pas, à elle seule, que l'interprétation de la relation est correcte. De même, les identifiants des sources cités par GraphRAG sont contrôlés, mais ce contrôle n'est pas une preuve automatique de chaque phrase de la réponse.

Sujets : références proposées	Valeur
Assertions attendues / prédites	64 / 60
Précision provisoire	0.900
Rappel provisoire	0.844
F1 provisoire	0.871

Les propositions de référence sont figées avant la campagne et ne sont jamais lues par le constructeur du graphe. Les différences détaillées sont conservées dans topics-v3-provisional-evaluation.json.

HDFS, Spark, Neo4j et GDS

Les 25 HTML et les 28 extractions ont été relus intégralement après écriture dans HDFS. Spark déduplique les documents et relations, produit une sortie JSON et une sortie Parquet HDFS. Le JSON Spark est importé dans les labels ResearchV3 et SourceV3. Les 42 entités et 54 relations historiques restent séparées, avec leur PageRank également vérifié.

3. Protocole comparatif

Dix questions couvrent des parcours d'une à trois relations, des intersections et une interprétation sémantique en français. Trois répétitions sont prévues dans chacun des deux protocoles : 60 paires et 120 résultats de méthode lorsque la campagne est complète.

Protocole	Entrées et traitement
Contrôlé	Le mode et les identifiants des graines sont fournis à Cypher. GraphRAG reçoit la question et récupère les faits à partir de ces graines, sans recevoir le résultat Cypher.
Question seule	Un planner reçoit la question et le catalogue des noms du graphe. Le même plan alimente Cypher et la récupération GraphRAG ; les références attendues ne sont pas fournies.

Question	Opération mesurée
mh1	Institutions des auteurs d'Attention - 2 sauts
mh2	Articles liés à la génération augmentée par récupération
mh3	Sujets des publications de Darren Edge - 2 sauts
mh4	Institutions liées aux graphes de connaissances - 3 sauts
mh5	Articles partageant un sujet avec Attention - 2 sauts
mh6	Sujets communs à Big Bird et Longformer
mh7	Auteurs communs à RAG et Retrieval Augmentation ... Conversation
mh8	Articles de récupération dense d'un auteur de RAG - 3 sauts
sem1	Méthodes pour guider le raisonnement des modèles
sem2	Prise en charge des longs contextes

GraphRAG explore le voisinage à trois sauts, avec un plafond explicite de 500 faits et un indicateur de troncature. Les réponses utilisent les noms canoniques du graphe et des sources connues. Le périmètre est une ontologie contrôlée : ces questions ne représentent pas toutes les formes possibles de recherche libre.

Un défaut Cypher excluait initialement le papier d'origine de mh8 en réutilisant une relation dans un seul MATCH. La requête a été séparée en deux MATCH et testée réellement dans Neo4j. Le checkpoint initial est archivé ; les requêtes Cypher ont été remesurées. Les réponses LLM ont été conservées car leurs entrées n'ont pas changé. L'empreinte inclut désormais les modèles de requête.

4. Résultats observés et interprétation

État de campagne : **complete** ; 60 paires complètes sur 60. Les lignes manquantes ne sont pas considérées comme des mesures. Les répétitions sur une même question ne sont pas des questions indépendantes.

Protocole	Méthode	n	F1 moy.	Exact	Médiane méthode (s)	Médiane avec plan (s)
controlled	cypher	30	0.956	0.800	0.024	0.024
controlled	graphrag	30	0.956	0.800	12.982	12.982
question_only	cypher	30	0.956	0.800	0.025	15.104
question_only	graphrag	30	0.956	0.800	11.648	25.984

Les médianes de méthode excluent le planner partagé. Les médianes avec plan additionnent son temps aux deux méthodes en question seule. Les temps incluent le logiciel client et l'environnement local. Les requêtes Cypher réévaluées après correction ne sont pas synchronisées avec les appels LLM conservés. Ces latences sont indicatives, sans machine dédiée ni réseau contrôlé.

GraphRAG	Réseau/SDK/fournisseur (s)	Attente locale/reprise (s)	Tokens entrée	Tokens sortie
controlled	2.773	10.821	797025	4599
question_only	2.186	6.524	797025	4599

Les tokens ci-dessus concernent les réponses GraphRAG, pas les plans. request_wall_s n'est pas un temps GPU. Les détails de planner_usage et le journal gemini-usage.jsonl permettent de reconstituer les appels. Les attentes sont publiées séparément au lieu d'être attribuées au calcul du modèle.

Ce que ces résultats permettent de dire

En question seule, le F1 moyen provisoire est de 0.956 pour Cypher et 0.956 pour GraphRAG. La médiane avec le planner partagé est de 15.10 s contre 25.98 s. Ces chiffres décrivent cette campagne, avec ses attentes de débit et sa variabilité réseau.

La mesure porte sur les ensembles de noms retournés. Elle ne note pas la qualité rédactionnelle d'une synthèse, son utilité pour un lecteur, ni la validité complète de chaque citation. Toutes les questions retenues sont exprimables avec les modèles Cypher disponibles.

Le benchmark doit être interprété sur ce corpus et cette ontologie. Une relation manquante dans le graphe peut pénaliser les deux méthodes. Une synthèse LLM n'apporte pas automatiquement de nouvelles preuves. Un gain éventuel sur une question ne démontre pas une supériorité générale ; l'égalité ne démontre pas non plus l'inutilité de GraphRAG sur d'autres tâches.

Les références étant proposées par l'assistant, toute conclusion de précision reste exploratoire jusqu'à la relecture indépendante des sujets, questions et ensembles attendus.

5. Reproduction, livrables et limites

Reproduire les étapes

build_corpus_graph_v3.py construit les 28 enregistrements sans lire les références. upload_raw_v3.py stocke et vérifie les HTML originaux. resume_infrastructure_v3.py vérifie les extractions HDFS, lance Spark puis importe sa sortie dans Neo4j. benchmark_v3.py reprend le checkpoint correspondant au graphe, aux références, au modèle et aux requêtes. finalize_benchmark_v3.py recalcule les agrégats.

Sans --allow-provisional, le benchmark refuse les références non relues. Le drapeau sert uniquement à une évaluation explicitement exploratoire. Le fichier relecture-sujets-questions-v3.html prépare la relecture des 25 annotations de sujets et des 10 questions ; son export recueille des avis sans attester automatiquement une identité ou une indépendance.

Déploiement vérifié

AGEO RECHERCHE est accessible sur http://127.0.0.1:8000/v3. L'API utilise l'image locale déjà fonctionnelle, avec app et static montés en lecture seule. Une reconstruction complète a rencontré une indisponibilité de pydantic_core==2.50.1 lors de l'installation ; cette même version fonctionne dans l'image existante. Une installation entièrement neuve reste à revalider. Les détails figurent dans DEPLOIEMENT.md.

Limites assumées

Le corpus contient 25 résumés et trois en-têtes PDF, sans mesure sur les articles complets. Les relations CITES et COLLABORATES_WITH ne sont pas évaluées ici. Les affiliations couvrent trois articles et peuvent manquer. Le rapprochement des auteurs par nom peut confondre des homonymes. Spark fonctionne sur un seul hôte en local[2] : aucune performance distribuée ou montée en charge n'est démontrée.

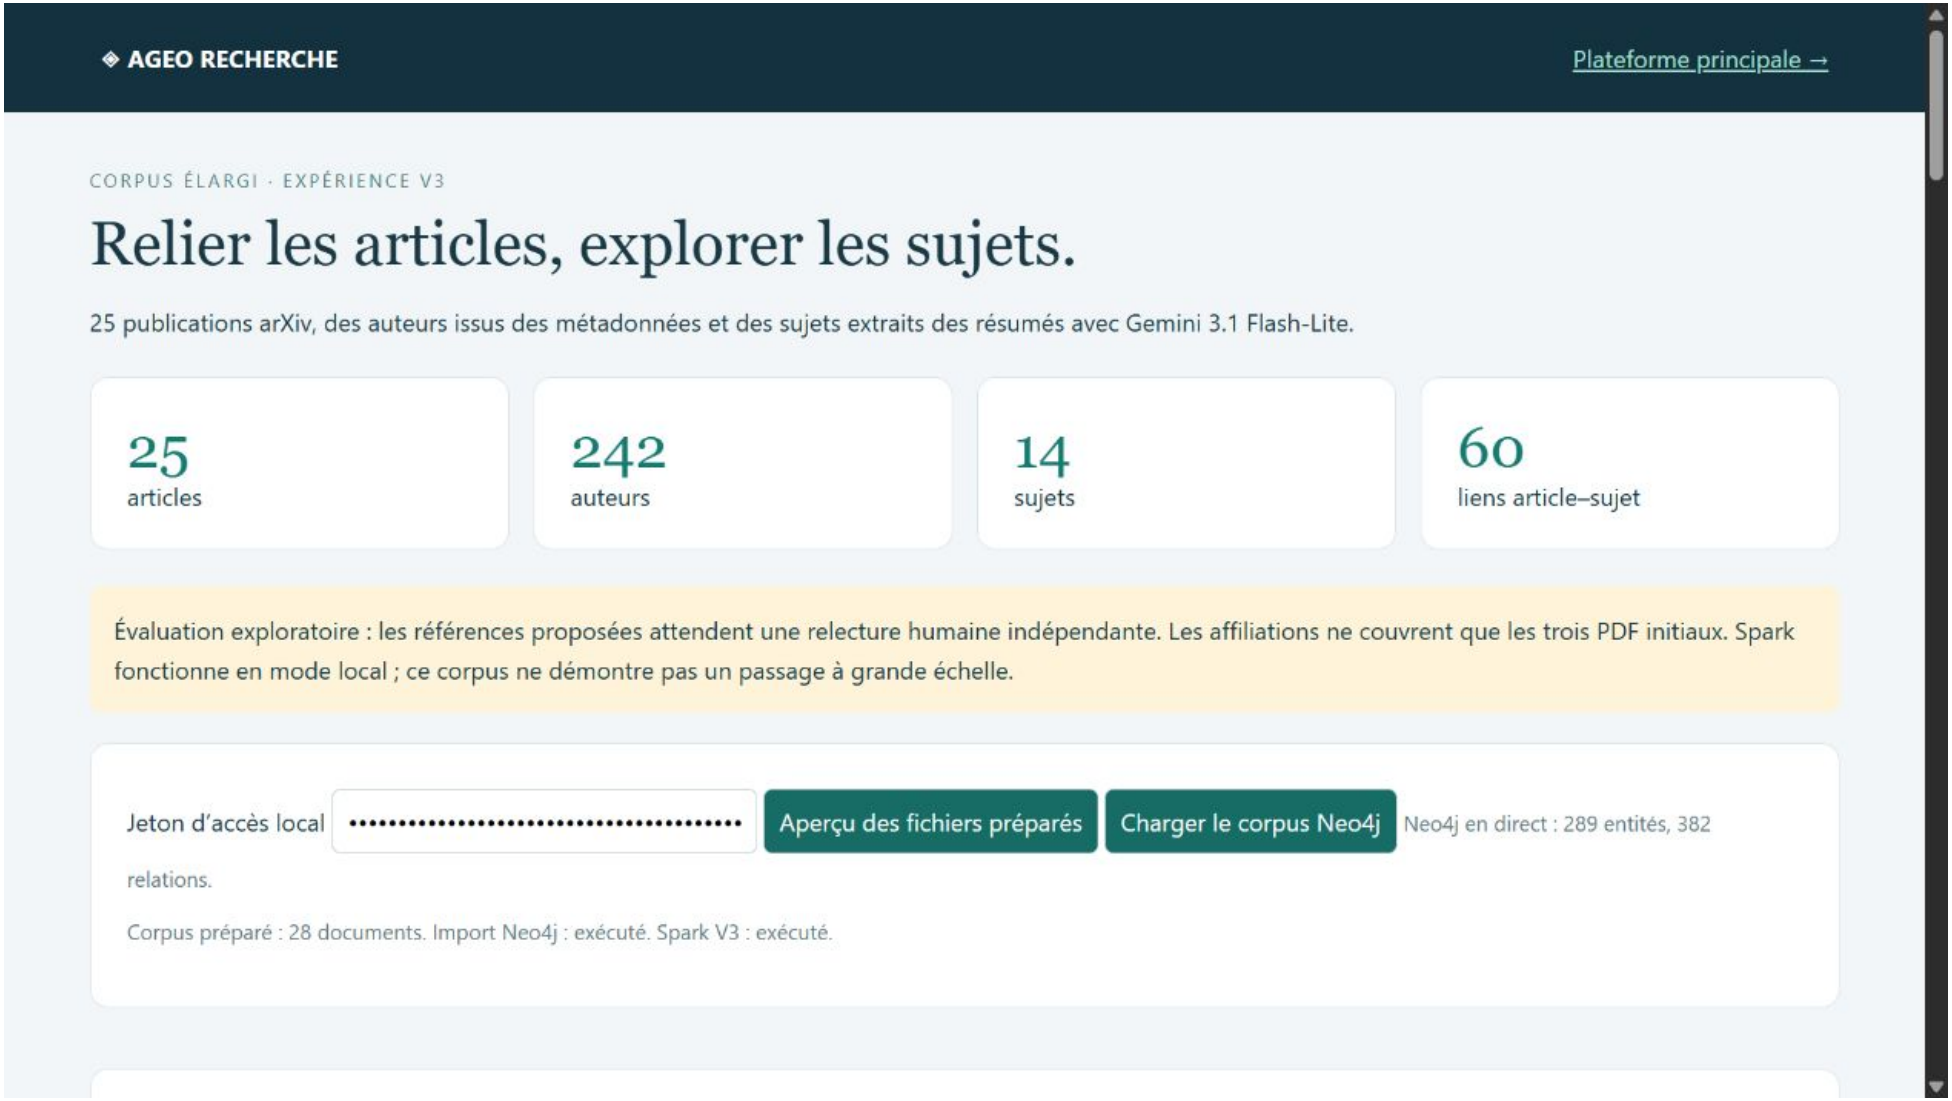
La récupération par parcours et l'interprétation LLM des sujets constituent ce prototype GraphRAG ; il ne met pas en œuvre une recherche vectorielle ou une synthèse de communautés à grande échelle. PageRank décrit la structure du graphe orienté et ne classe pas la qualité des publications.

Sources et preuves disponibles

Sources arXiv : identifiants de la section 1 ; textes bruts et empreintes dans data/corpus-v3/articles.json. Gratuité proposée du modèle : documentation tarifaire officielle Gemini. Les secrets ne figurent pas dans les archives. Les captures suivantes distinguent les données en direct, les journaux enregistrés et le benchmark sauvegardé.

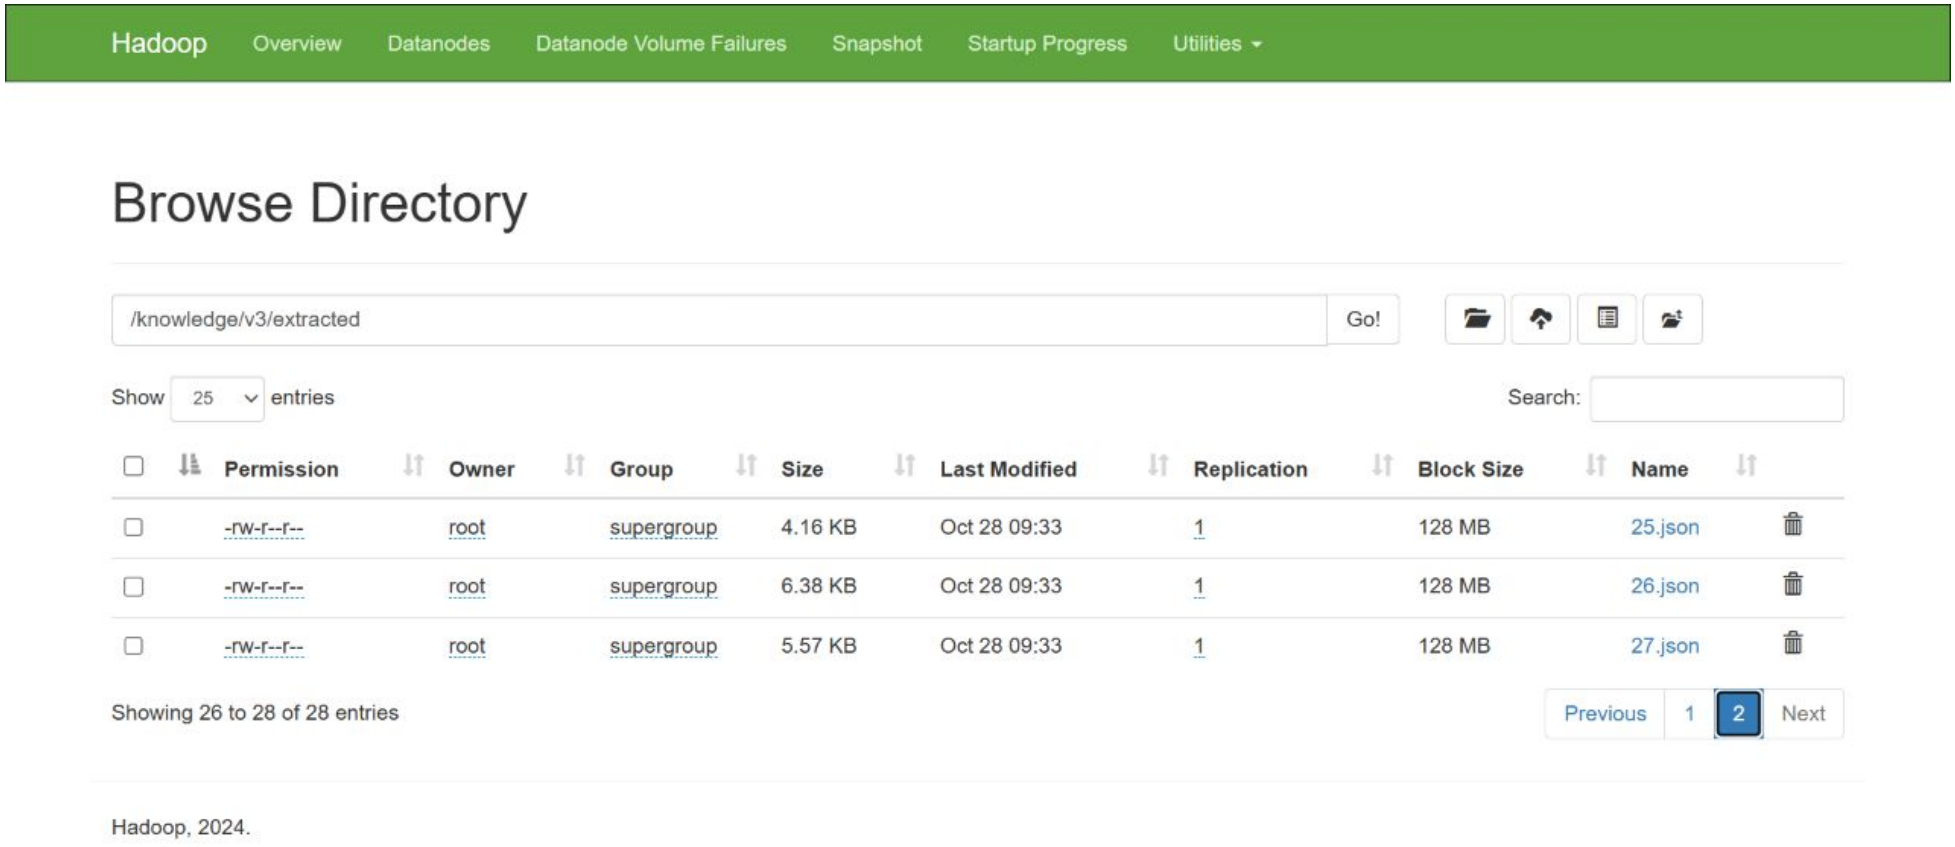
Artefacts : rapport-projet-v3.pdf ; projet-bigdata-v3.zip ; relecture-sujets-questions-v3.html ; reports/benchmark-v3-summary.json ; reports/neo4j-v3.json ; reports/hdfs-v3-verified.json ; reports/hdfs-v3-raw-verified.json ; reports/tests-v3-expanded.log.

Corpus V3 déployé



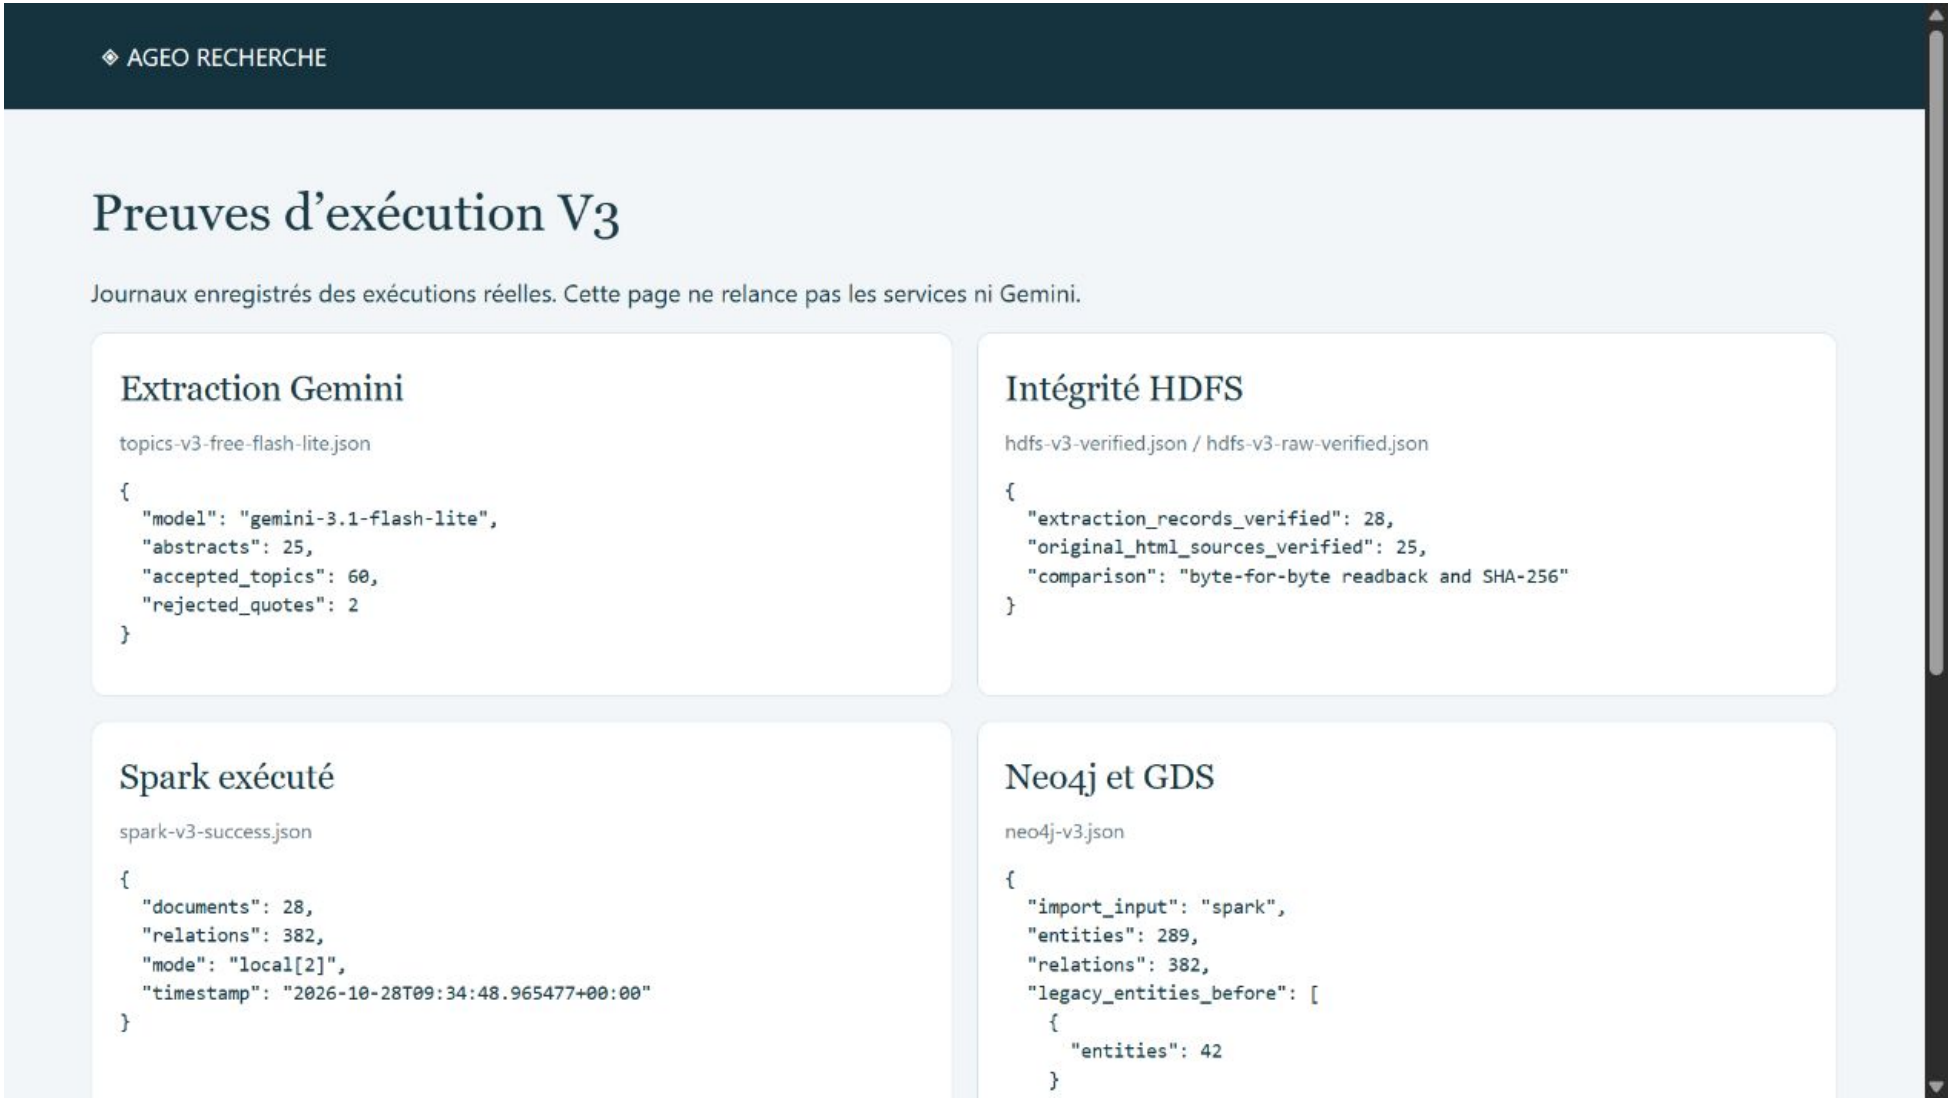
La plateforme indique les comptes du corpus et les étapes exécutées. Le graphe a été chargé depuis Neo4j, pas depuis l'aperçu local.

Stockage HDFS des extractions



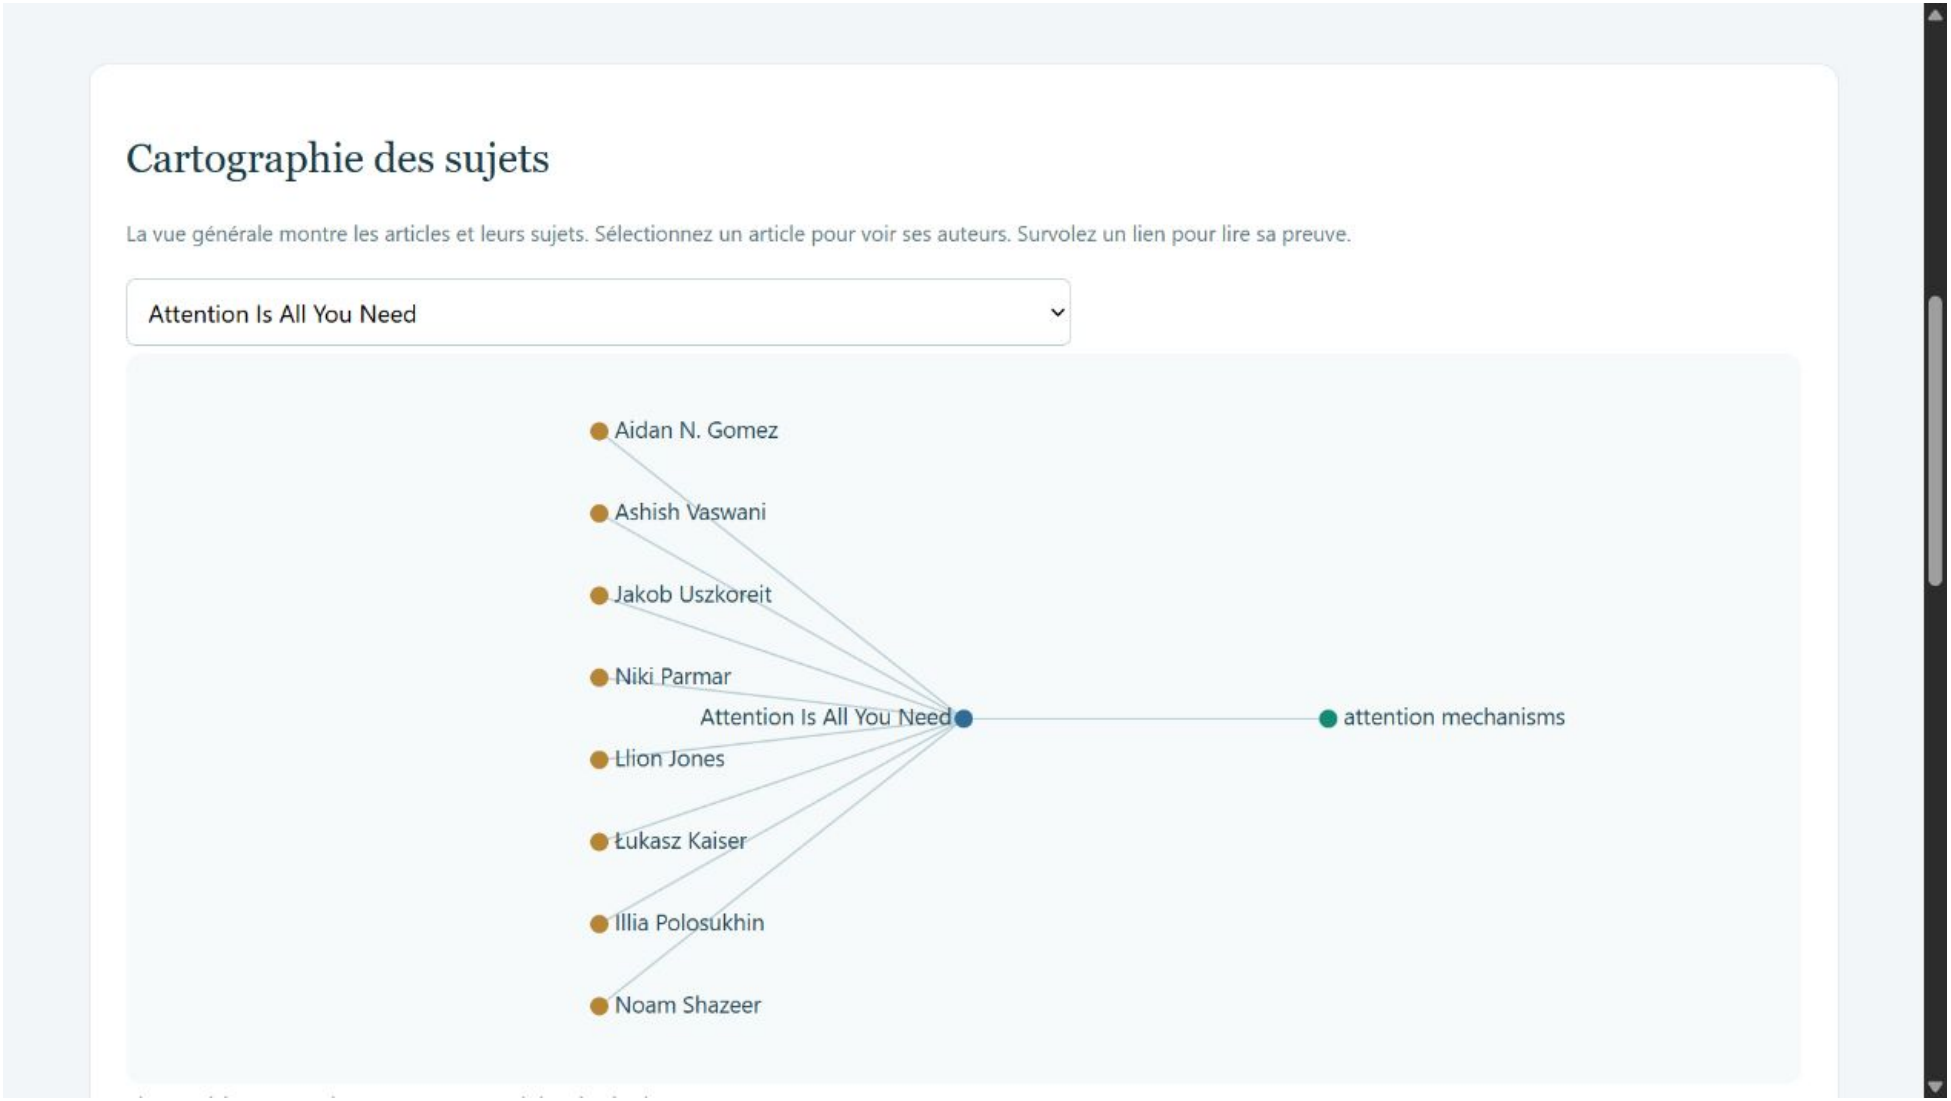
Dernière page de la liste : le total affiché est 28 fichiers. Les 25 HTML originaux sont également stockés dans raw-html et vérifiés par relecture.

Journaux enregistrés du pipeline



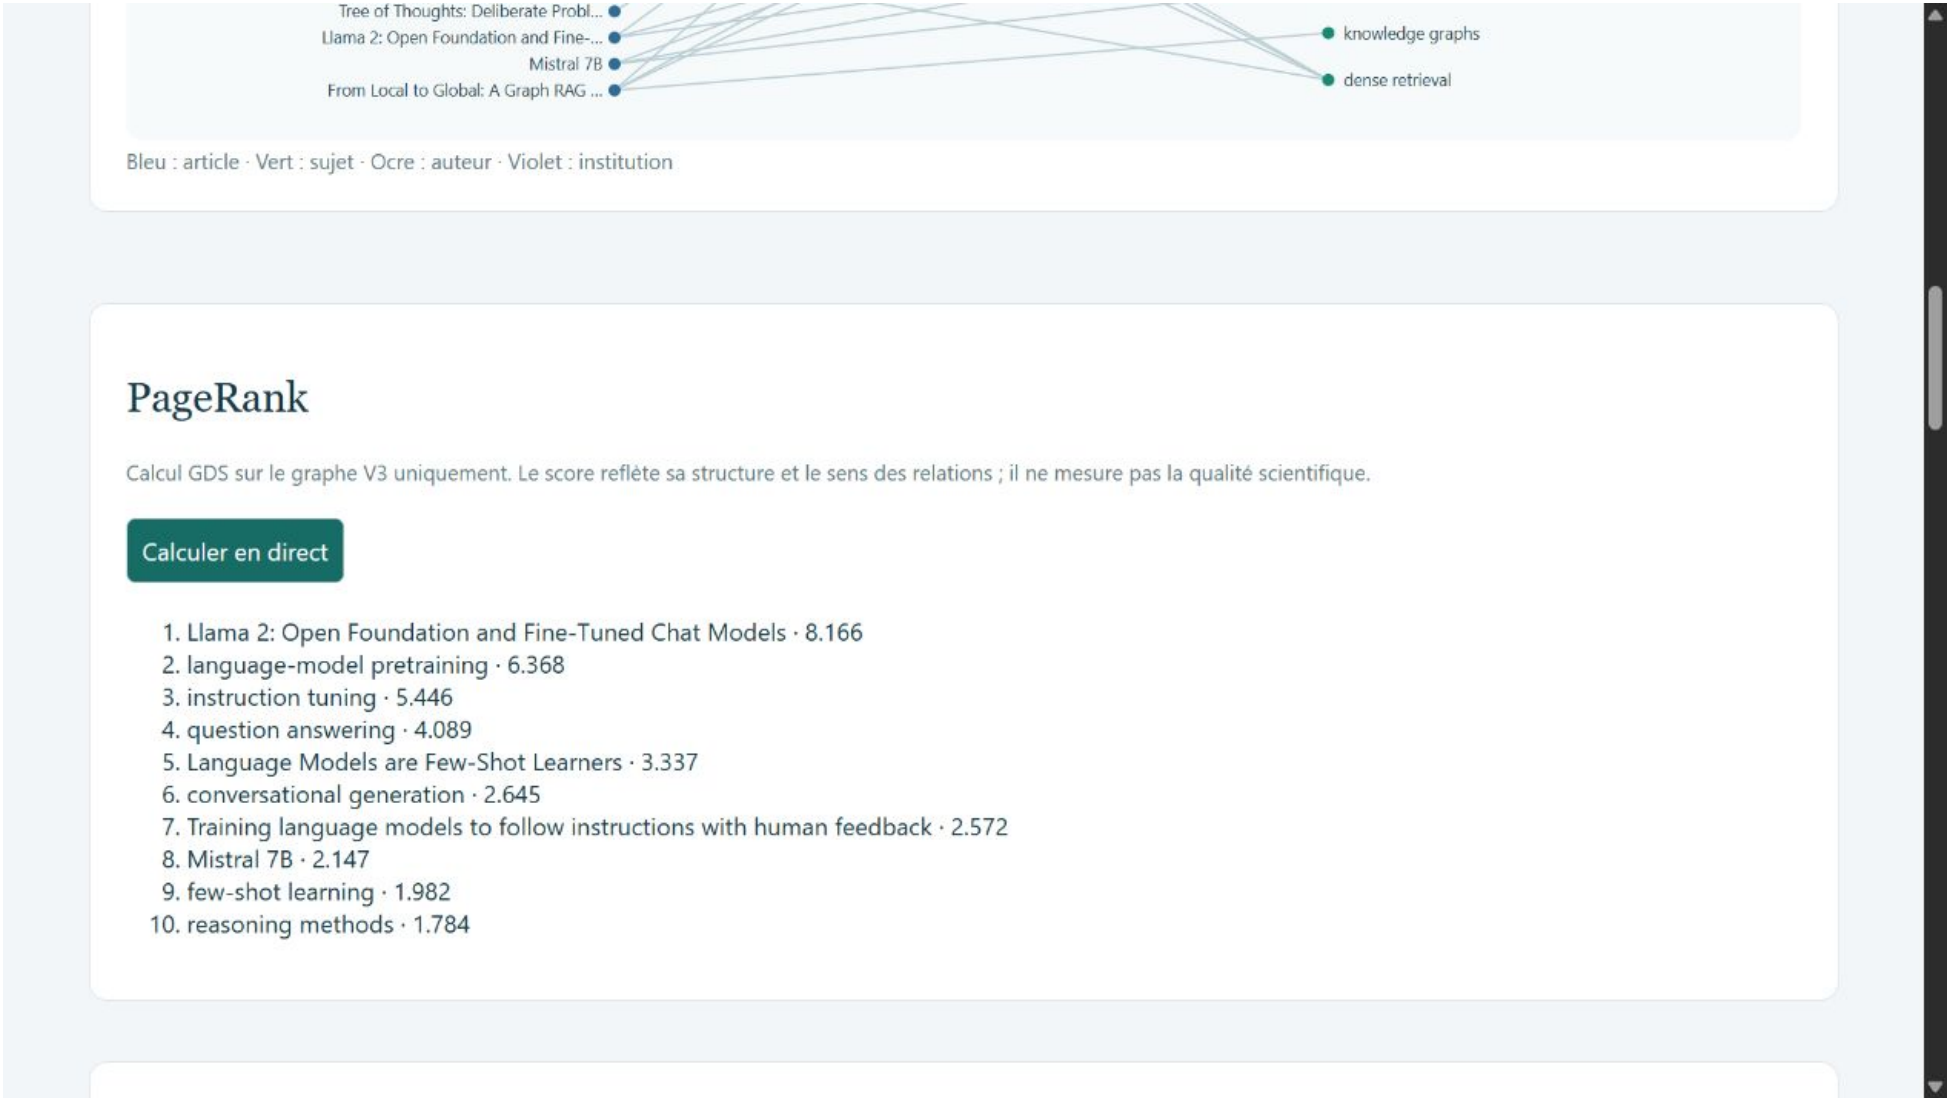
Vue des résultats enregistrés de l'extraction, de l'intégrité HDFS et de Spark. Cette page ne prétend pas être un terminal ou une nouvelle exécution.

Auteurs d’Attention et sujet associé



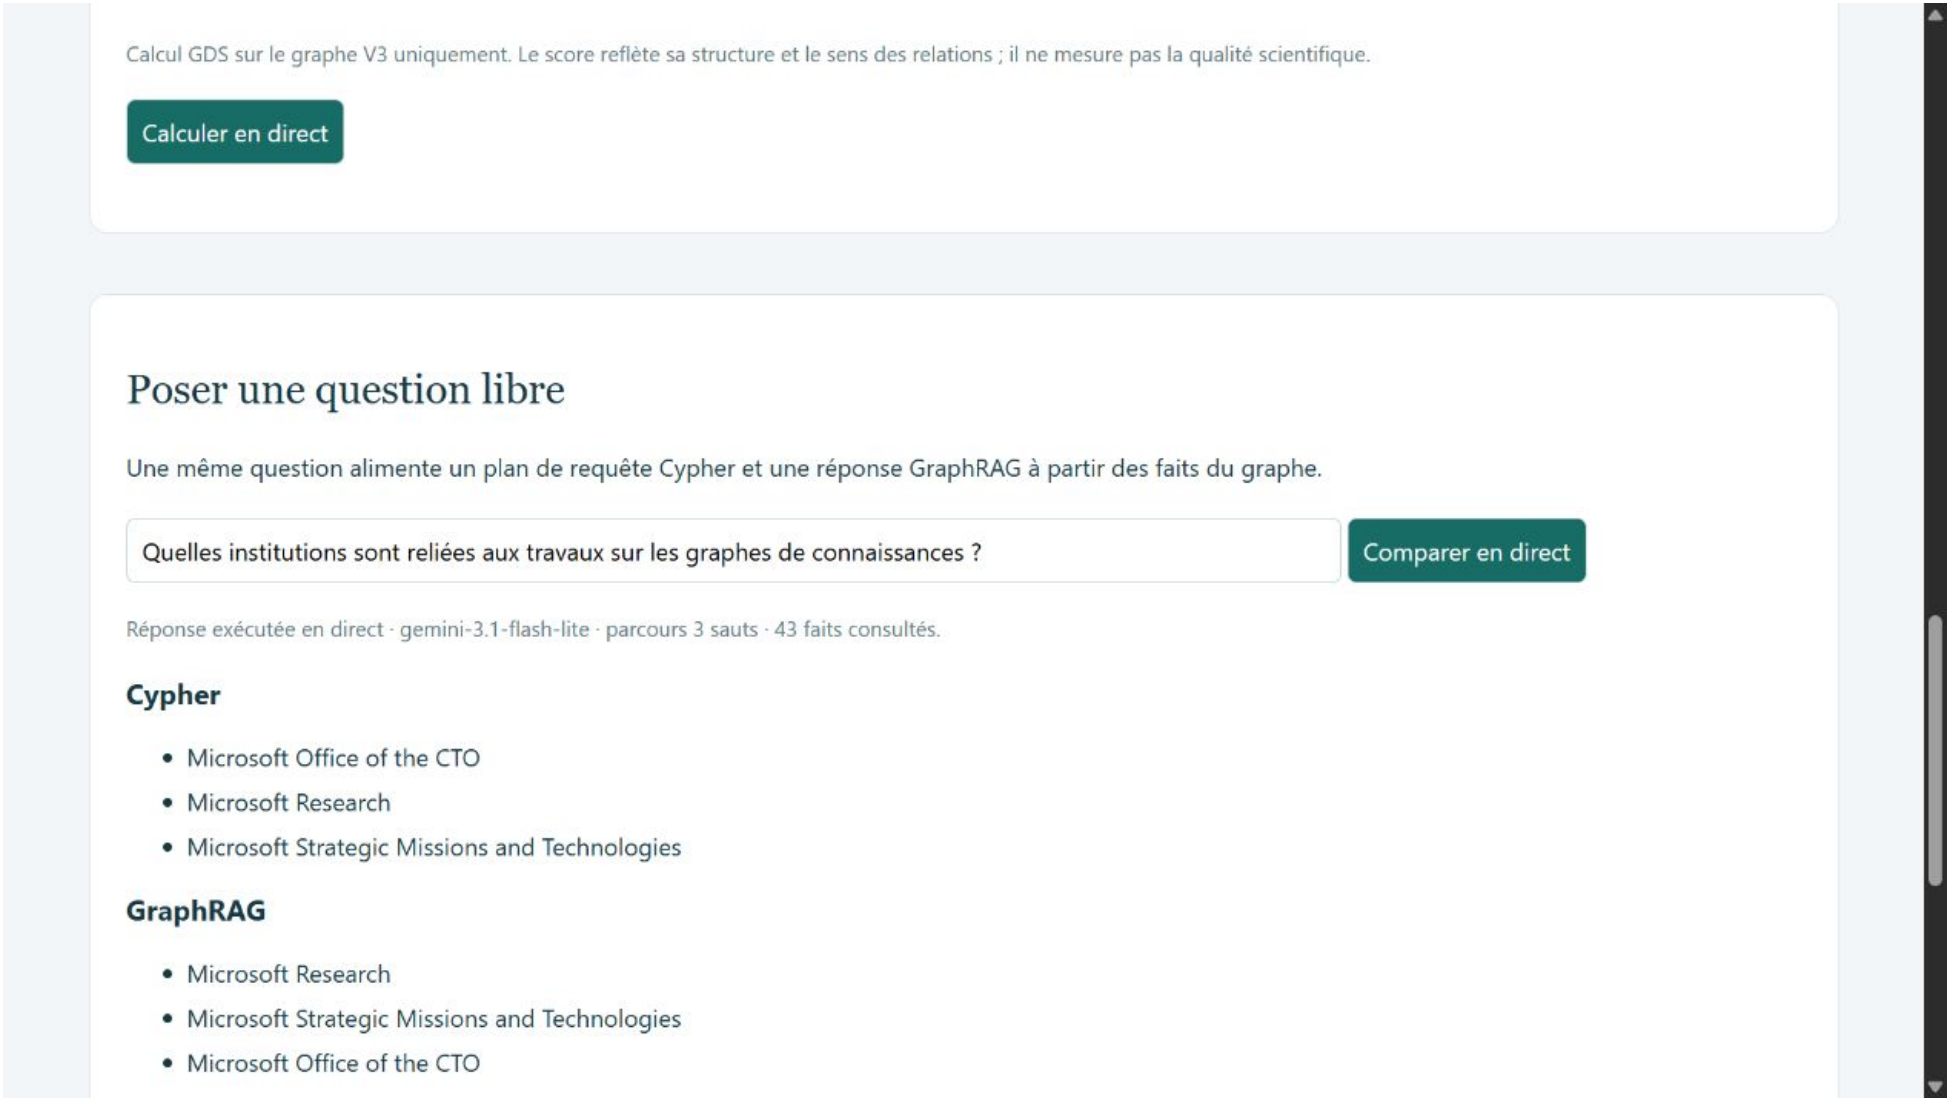
Vue chargée depuis Neo4j avec les huit auteurs. Les noms sont lisibles et les symboles de notes ne sont pas ajoutés aux noms canoniques.

PageRank calculé avec GDS



Scores retournés en direct sur ResearchV3 uniquement. La centralité dépend notamment du nombre d'auteurs et de l'orientation des relations.

Comparaison exécutée en direct



Appel Gemini déclenché depuis le navigateur. La réponse, le modèle et le statut de direct sont visibles ; ce n'est pas une réponse enregistrée du benchmark.

Benchmark enregistré

- Microsoft Strategic Missions and Technologies
- Microsoft Office of the CTO

Les institutions reliées aux travaux sur les graphes de connaissances, tels que présentés dans le document sur l'approche GraphRAG, sont Microsoft Research, Microsoft Strategic Missions and Technologies et Microsoft Office of the CTO.

Sources citées : v3:pdf:graphrag

Benchmark multi-sauts et sémantique

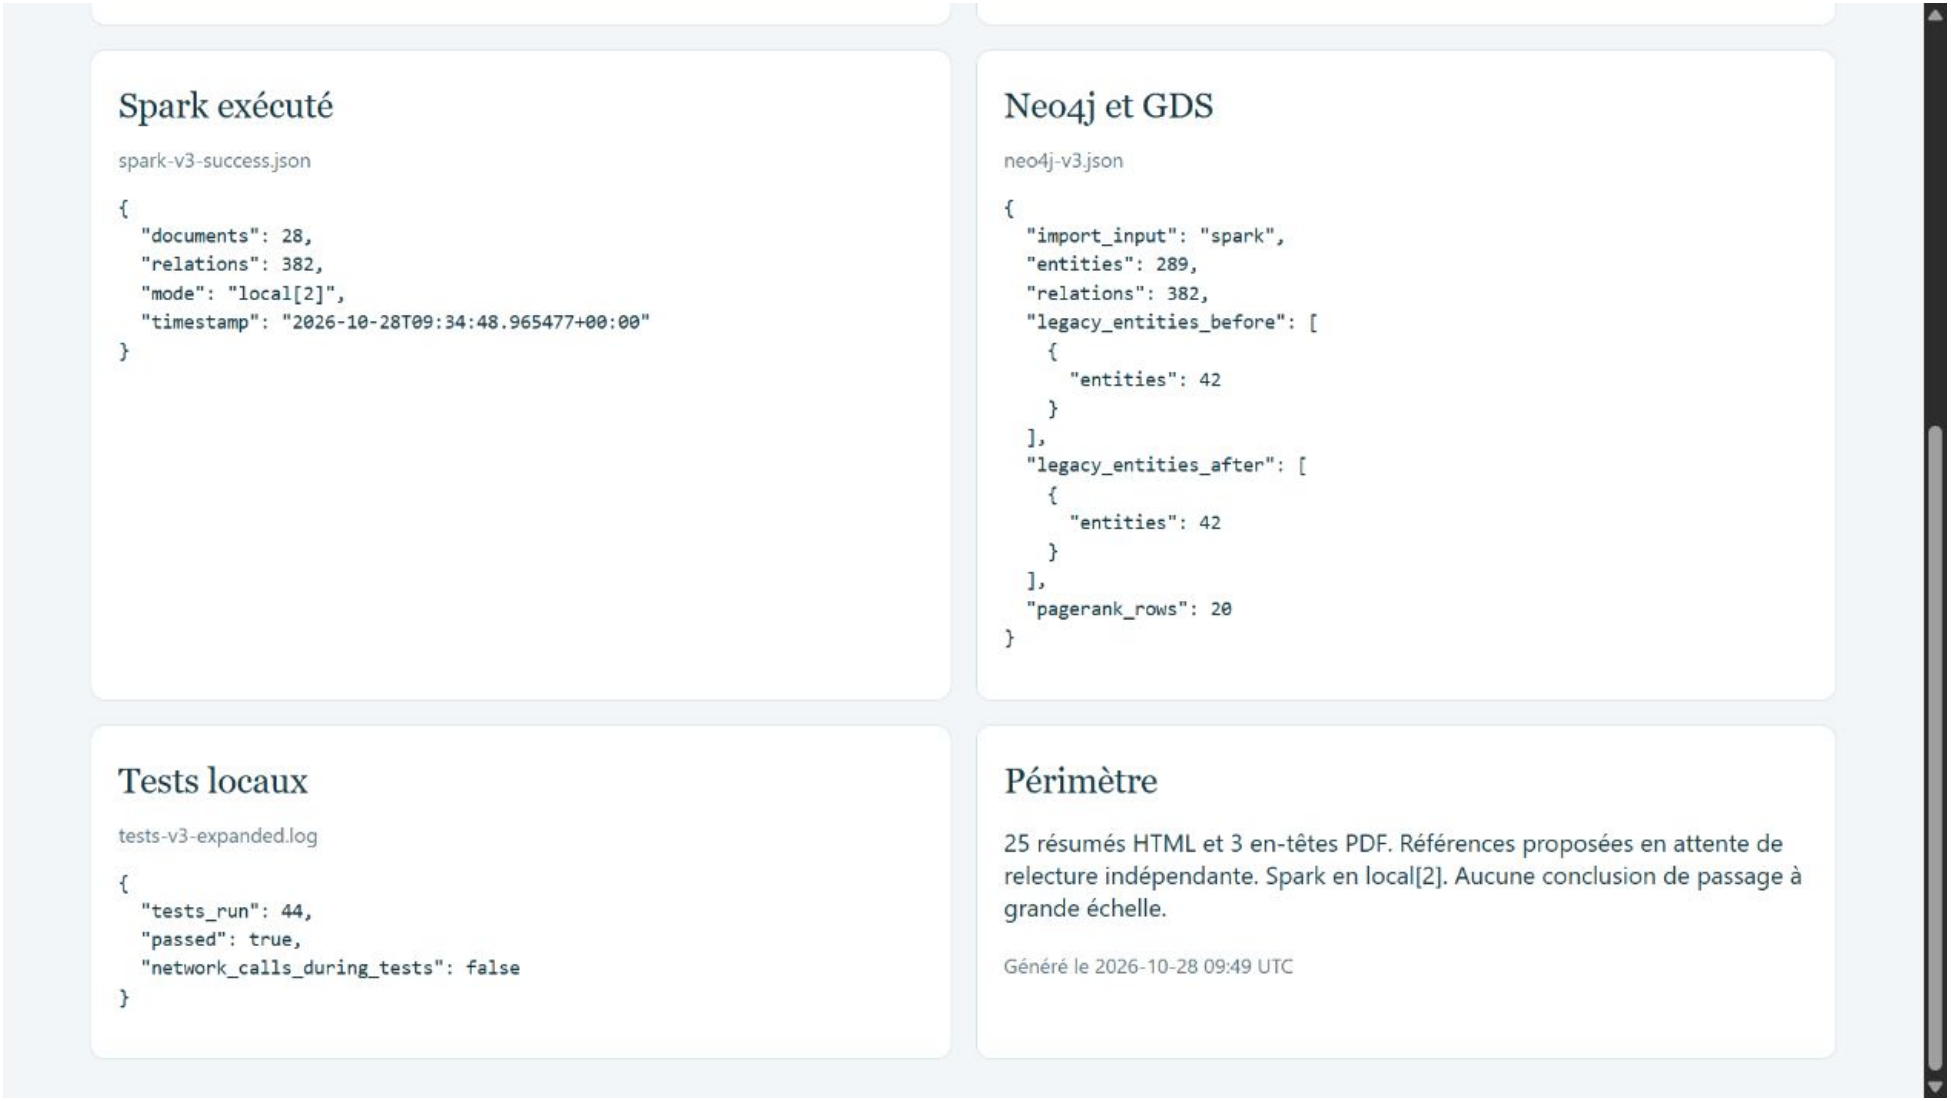
Charger les mesures enregistrées

État : complete · 60/60 comparaisons terminées · références : pending_independent_human_review. Mesures exploratoires, sans conclusion de supériorité.

Question / répétition	Protocole	F1 Cypher	F1 GraphRAG	Cypher + plan (s)	GraphRAG + plan (s)	Réseau GraphRAG	Attente GraphRAG
mh1 / 1	controlled	1.00	1.00	0.03	3.22	2.91 s	0.00 s
mh1 / 1	question_only	1.00	1.00	16.00	24.74	1.70 s	6.97 s
mh2 / 1	controlled	1.00	1.00	0.02	15.11	3.97 s	11.08 s
mh2 / 1	question_only	1.00	1.00	13.47	26.92	4.96 s	8.44 s
mh3 / 1	controlled	0.89	0.89	0.02	10.06	2.20 s	7.80 s
mh3 / 1	question_only	0.89	0.89	13.33	49.03	25.25 s	10.42 s
mh4 / 1	controlled	1.00	1.00	0.02	7.44	7.38 s	0.00 s

Extrait des mesures sauvegardées avec le nombre total de paires terminées. La page distingue le temps réseau/fournisseur de l'attente locale.

Spark, Neo4j et tests



Spark exécuté

spark-v3-success.json


```
{
  "documents": 28,
  "relations": 382,
  "mode": "local[2]",
  "timestamp": "2026-10-28T09:34:48.965477+00:00"
}
```


Neo4j et GDS

neo4j-v3.json


```
{
  "import_input": "spark",
  "entities": 289,
  "relations": 382,
  "legacy_entities_before": [
    {
      "entities": 42
    }
  ],
  "legacy_entities_after": [
    {
      "entities": 42
    }
  ],
  "pagerank_rows": 20
}
```


Tests locaux

tests-v3-expanded.log


```
{
  "tests_run": 44,
  "passed": true,
  "network_calls_during_tests": false
}
```


Périmètre

25 résumés HTML et 3 en-têtes PDF. Références proposées en attente de relecture indépendante. Spark en local[2]. Aucune conclusion de passage à grande échelle.

Généré le 2026-10-28 09:49 UTC

Journaux enregistrés : 28 documents traités par Spark, 289 entités importées, PageRank et 44 tests locaux réussis.